

Introduction to Deep Learning - Projet de validation

Ambroise BOURU--GAZEAU

Objectifs

Le projet consiste à choisir un ou plusieurs papiers scientifiques en deep learning, à en identifier les idées centrales puis les reproduire dans un cadre simplifié.

Le but n'est pas de reproduire exactement tous les résultats des papiers, ni d'atteindre les performances publiées sur des benchmarks avec des millions de données. L'objectif est plutôt d'être capable de :

- isoler l'idée principale d'un papier et comprendre la contribution par rapport à l'état de l'art
- l'implémenter ou l'évaluer dans d'autres conditions que celles du papier, parfois plus simplement
- réaliser une ablation ou faire varier certains paramètres de la méthode
- analyser les résultats obtenus

Les projets seront réalisés par groupes de **trois ou quatre**.

Reproduction attendue

J'attends une reproduction **réduite mais rigoureuse**. Chaque groupe devra définir clairement :

- ce qui est reproduit du ou des papiers originaux
- ce qui est simplifié
- ce qui est évalué expérimentalement
- à quelle baseline on se compare
- quelle ablation permet de tester quelle hypothèse

Exemple de reproductions possibles :

- réimplémenter les architectures proposées dans les papiers et les appliquer à de nouvelles données
- reproduire une loss ou un protocole d'entraînement
- utiliser un modèle pré-entraîné et reproduire une analyse expérimentale
- étudier les limites ou les cas d'échec d'une méthode

Contraintes matérielles

Les papiers ont été sélectionnés pour être réalisables avec **Google Colab**. Les ressources GPU disponibles pouvant varier, je vous déconseille de vous lancer dans des projets qui se basent sur des modèles trop lourds, un jeu de données trop grand ou un entraînement trop long.

Je vous conseille donc :

- D'utiliser un dataset raisonnable : CIFAR-10/100, STL-10, Oxford-IIIT Pet, Pascal VOC, Tiny-ImageNet, Fashion-MNIST, ou un dataset de votre choix trouvable sur Kaggle ou Huggingface
- Si plusieurs architectures sont proposées dans le papier, utiliser les plus petites (celles avec le moins de poids à entraîner)
- Enregistrer de manière régulière vos checkpoints d'entraînement

- Vous baser sur les implémentations officielles des papiers, les liens vers les repo git sont disponibles dans les articles
- Enregistrer à part les données qui servent à produire vos figures ou tableaux de résultats
- Utiliser un modèle pré-entraîné lorsque le papier original est trop coûteux à reproduire

Livrables

Chaque groupe devra rendre :

1. un rapport écrit si possible avec le template $\text{\LaTeX}$ suivant : [Template](#)
2. un notebook principal ou un script reproductible des principaux résultats de vos expériences
3. un dépôt Git ou une archive contenant le code

Structure recommandée du rapport

1. Introduction

- Le papier choisi, les données et l'angle principal de votre analyse

2. Méthode

- Architecture ou module étudié, loss utilisées...
- Les différences de cette méthode avec une baseline classique

3. Cadre de reproduction

- Dataset utilisé et les prétraitements sur les données
- Les métriques que vous étudiez ou les objets sur lesquels se basent vos analyses
- Qu'avez vous changé ou simplifié par rapport au papier initial

4. Résultats

- Reproduction principale et comparaison à une baseline
- Figures, tableaux et exemples qualitatifs, allez droit au but et essayez de mettre des figures qui condensent l'information tout en restant compréhensibles

5. Ablation ou extension

- Composant retiré ou modifié, paramètres changés,...
- Motivation et hypothèses
- Résultats obtenus et interprétations

6. Discussion critique

- Ce qui fonctionne ou pas
- Les différences avec le papier initial et les limites possibles de votre travail

Barème indicatif

Critère	Part
Compréhension du papier et clarté de l'explication	20%
Qualité de la reproduction ou de l'évaluation expérimentale	20%
Pertinence de la baseline et des métriques	15%
Ablation ou extension personnelle	25%
Analyse critique des résultats et des limites	15%
Qualité et reproductibilité du code	5%

N'hésitez pas à évoquer ce qui ne marche pas ou mal, un résultat mauvais sera bien évalué si l'analyse est critique et honnête. De la même manière, un projet trop ambitieux et mal compris pourra être pénalisé par rapport à une reproduction/extension plus simple mais maîtrisée.

Le but premier n'est pas d'obtenir les meilleures performances mais de montrer :

- Quelle idée scientifique a été testée
- Comment elle a été reproduite
- Quelles variations modifient les résultats et quelles seraient les raisons derrière cela
- Quelles limites empêchent de conclure davantage

Papiers proposés

La liste suivante constitue une banque volontairement large sur des sujets divers. Pour éviter toute confusion, chaque sujet indique une référence bibliographique. Si vous rencontrez des difficultés pour récupérer un papier, contactez-moi.

A. Architectures CNN

- **ConvNeXt** – Liu et al., *A ConvNet for the 2020s*, CVPR 2022, [arXiv:2201.03545](#).
- **ConvNeXt V2** – Woo et al., *ConvNeXt V2 : Co-designing and Scaling ConvNets with Masked Autoencoders*, CVPR 2023, [arXiv:2301.00808](#).
- **RepVGG** – Ding et al., *RepVGG : Making VGG-style ConvNets Great Again*, CVPR 2021, [arXiv:2101.03697](#).
- **RegNet** – Radosavovic et al., *Designing Network Design Spaces*, CVPR 2020, [arXiv:2003.13678](#).
- **HorNet** – Rao et al., *HorNet : Efficient High-Order Spatial Interactions with Recursive Gated Convolutions*, NeurIPS 2022, [arXiv:2207.14284](#).
- **ConvMixer** – Trockman et al., *Patches Are All You Need ?*, arXiv 2022, [arXiv:2201.09792](#).

B. Architectures hybrides CNN/Transformer

- **MobileViT** – Mehta et al., *MobileViT : Light-weight, General-purpose, and Mobile-friendly Vision Transformer*, ICLR 2022, [arXiv:2110.02178](#).
- **CvT** – Wu et al., *CvT : Introducing Convolutions to Vision Transformers*, ICCV 2021, [arXiv:2103.15808](#).
- **CoAtNet** – Dai et al., *CoAtNet : Marrying Convolution and Attention for All Data Sizes*, arXiv 2021, [arXiv:2106.04803](#).
- **Swin Transformer** – Liu et al., *Swin Transformer : Hierarchical Vision Transformer using Shifted Windows*, ICCV 2021, [arXiv:2103.14030](#).

C. Self-supervised learning

- **MAE** – He et al., *Masked Autoencoders Are Scalable Vision Learners*, CVPR 2022, [arXiv:2111.06377](#).
- **DINO** – Caron et al., *Emerging Properties in Self-Supervised Vision Transformers*, ICCV 2021, [arXiv:2104.14294](#).
- **DINOv2** – Oquab et al., *DINOv2 : Learning Robust Visual Features without Supervision*, arXiv 2023, [arXiv:2304.07193](#).
- **Barlow Twins** – Zbontar et al., *Barlow Twins : Self-Supervised Learning via Redundancy Reduction*, ICML 2021, [arXiv:2103.03230](#).
- **SimSiam** – Chen et al., *Exploring Simple Siamese Representation Learning*, CVPR 2021, [arXiv:2011.10566](#).
- **MSN** – Assran et al., *Masked Siamese Networks for Label-Efficient Learning*, ECCV 2022, [arXiv:2204.07141](#).

D. Segmentation et foundation models

- **SegFormer** – Xie et al., *SegFormer : Simple and Efficient Design for Semantic Segmentation with Transformers*, NeurIPS 2021, [arXiv:2105.15203](#).
- **Segment Anything / SAM** – Kirillov et al., *Segment Anything*, ICCV 2023, [arXiv:2304.02643](#).
- **EfficientSAM** – Xiong et al., *EfficientSAM : Leveraged Masked Image Pretraining for Efficient Segment Anything*, CVPR 2024, [arXiv:2312.00863](#).
- **FastSAM** – Zhao et al., *Fast Segment Anything*, arXiv 2023, [arXiv:2306.12156](#).
- **nnU-Net** – Isensee et al., *nnU-Net : a self-configuring method for deep learning-based biomedical image segmentation*, Nature Methods 2021, [doi:10.1038/s41592-020-01008-z](#).

E. Détection d’objets

- **Grounding DINO** – Liu et al., *Grounding DINO : Marrying DINO with Grounded Pre-Training for Open-Set Object Detection*, arXiv 2023, [arXiv:2303.05499](#).
- **YOLOv10** – Wang et al., *YOLOv10 : Real-Time End-to-End Object Detection*, NeurIPS 2024, [arXiv:2405.14458](#).
- **YOLOX** – Ge et al., *YOLOX : Exceeding YOLO Series in 2021*, arXiv 2021, [arXiv:2107.08430](#).
- **Sparse R-CNN** – Sun et al., *Sparse R-CNN : End-to-End Object Detection with Learnable Proposals*, CVPR 2021, [arXiv:2011.12450](#).

F. Explicabilité et interprétation

- **Grad-CAM++** : Chattopadhyay et al., *Grad-CAM++ : Improved Visual Explanations for Deep Convolutional Networks*, arXiv :1710.11063, 2017. [arXiv:1710.11063](#).
- **XGrad-CAM** : Fu et al., *Axiom-based Grad-CAM : Towards Accurate Visualization and Explanation of CNNs*, BMVC, 2020. [arXiv:2008.02312](#).
- **LayerCAM** : Jiang et al., *LayerCAM : Exploring Hierarchical Class Activation Maps for Localization*, IEEE Transactions on Image Processing, 2021. [doi:10.1109/TIP.2021.3089943](#).
- **Eigen-CAM** : Muhammad et al., *Eigen-CAM : Class Activation Map using Principal Components*, arXiv :2008.00299, 2020. [arXiv:2008.00299](#).
- **Layer-wise Relevance Propagation** : Bach et al., *On Pixel-Wise Explanations for Non-Linear Classifier Decisions by Layer-Wise Relevance Propagation*, PLOS ONE, 2015. [doi:10.1371/journal.pone.0130140](#).
- **LIME** : Ribeiro et al., “*Why Should I Trust You ?*” : *Explaining the Predictions of Any Classifier*, KDD, 2016. [arXiv:1602.04938](#).
- **Extremal Perturbations** : Fong et al., *Understanding Deep Networks via Extremal Perturbations and Smooth Masks*, ICCV, 2019. [arXiv:1910.08485](#).

G. Génération

- **VQ-VAE** – van den Oord et al., *Neural Discrete Representation Learning*, NeurIPS 2017, [arXiv:1711.00937](#).
- **WGAN** – Arjovsky et al., *Wasserstein GAN*, ICML 2017, [arXiv:1701.07875](#).
- **LSGAN** – Mao et al., *Least Squares Generative Adversarial Networks*, ICCV 2017, [arXiv:1611.04076](#).
- **Pix2Pix** – Isola et al., *Image-to-Image Translation with Conditional Adversarial Networks*, CVPR 2017, [arXiv:1611.07004](#).
- **CycleGAN** – Zhu et al., *Unpaired Image-to-Image Translation using Cycle-Consistent Adversarial Networks*, ICCV 2017, [arXiv:1703.10593](#).
- **DDPM** – Ho et al., *Denoising Diffusion Probabilistic Models*, NeurIPS 2020, [arXiv:2006.11239](#).
- **Classifier-Free Guidance** – Ho et al., *Classifier-Free Diffusion Guidance*, arXiv 2022, [arXiv:2207.12598](#).

Attribution des papiers

Chaque groupe devra m’envoyer une liste classée de papiers qu’il aimerait traiter puis je les validerai rapidement. Je n’ai aucun problème avec le fait que plusieurs groupes travaillent sur les mêmes papiers tant que les datasets ou les ablations sont différentes. Néanmoins, afin d’éviter une trop grande uniformité des sujets choisis, je me réserve le droit de ne pas vous donner votre premier choix.

Si vous rencontrez des difficultés lors de votre projet vous pouvez me contacter à tout moment.