

Reproduction réduite de DINO

Emerging Properties in Self-Supervised Vision Transformers
sur STL-10 avec un ViT-Tiny

Namie Pajot Alexandra Arucan Mael Zapata Philipp Widenfels
Albert School — Bachelor Business & Data (3^e année)
Cours : Introduction to Deep Learning — A. Bouru-Gazeau

June 8, 2026

Abstract

Nous reproduisons, dans un cadre volontairement réduit mais rigoureux, l'idée centrale de **DINO** [1] : l'apprentissage auto-supervisé de représentations visuelles par *self-distillation* avec un réseau enseignant construit comme moyenne mobile exponentielle (EMA) de l'étudiant, sans aucune étiquette. Nous entraînons un Vision Transformer *ViT-Tiny* (patch 8, $\sim 5\text{--}6\text{M}$ paramètres) sur le jeu de données STL-10, évaluons la qualité des représentations gelées par un classifieur k -NN, et comparons à deux lignes de base de même architecture (initialisation aléatoire et entraînement supervisé). Nous reproduisons qualitativement la propriété émergente phare du papier — des cartes d'auto-attention qui segmentent les objets sans supervision — et menons trois ablations inspirées de la Table 7 du papier (encodeur à momentum, multi-crop, température de l'enseignant). Notre but n'est pas d'égaler les performances ImageNet du papier mais de montrer que le mécanisme fonctionne à échelle réduite et que nos ablations en retrouvent qualitativement les conclusions.

1 Introduction

Papier choisi. DINO — *Emerging Properties in Self-Supervised Vision Transformers*, Caron *et al.*, ICCV 2021 (arXiv:2104.14294) [1]. DINO (*self-distillation with **no** labels*) est une méthode d'apprentissage auto-supervisé (SSL) qui apprend des représentations visuelles sans étiquettes en faisant correspondre les sorties d'un réseau *étudiant* à celles d'un réseau *enseignant* construit à partir de l'étudiant lui-même.

Pourquoi ce papier. Trois raisons ont motivé ce choix. (i) *Pertinence* : le pré-entraînement auto-supervisé répond directement au coût d'annotation, goulot d'étranglement des pipelines réels ; DINOv2 (Meta, 2023) en est le descendant direct et largement utilisé en production. (ii) *Évaluabilité* : la contribution est à la fois quantitative (précision k -NN de représentations gelées) et qualitative (cartes d'attention qui segmentent les objets), ce qui donne un rapport plus riche. (iii) *Faisabilité* : l'algorithme tient en ~ 15 lignes de pseudo-code (Algorithme 1 du papier), ce qui rend une reproduction réduite réaliste sur Colab. Les alternatives envisagées (MAE, Barlow Twins, DDPM) ont été écartées respectivement pour un résultat visuel moins frappant à petite échelle, un espace d'ablation plus pauvre, et un coût de calcul incompatible avec Colab.

Données et angle d'analyse. Nous travaillons sur **STL-10**, choisi pour sa résolution 96×96 (adaptée à la tokenisation en patches d'un ViT) et son *split non étiqueté* de 100 000 images, conçu pour le SSL. Notre angle est double :

1. **quantitatif** — la représentation auto-supervisée est-elle utile sans fine-tuning ? Mesure par k -NN à features gelées, comparée à une ligne de base supervisée de même architecture et à une borne basse (initialisation aléatoire) ;

2. **qualitatif et mécaniste** — la propriété émergente (attention sémantique) se manifeste-t-elle à échelle réduite, et quels composants sont *indispensables* pour éviter l’effondrement (*collapse*) des représentations ? C’est l’objet de nos ablations.

2 Méthode

2.1 Vue d’ensemble de DINO

DINO entraîne deux réseaux de même architecture, un étudiant g_{θ_s} et un enseignant g_{θ_t} . Chacun est composé d’un *backbone* (ici un ViT) suivi d’une tête de projection produisant un vecteur de dimension K , transformé en distribution de probabilité par un softmax avec température. L’objectif est de rendre la distribution de l’étudiant cohérente avec celle de l’enseignant sur *des vues différentes de la même image*.

Multi-crop. À partir d’une image, on génère un ensemble de vues : 2 vues *globales* (grandes) et plusieurs vues *locales* (petites). L’enseignant ne voit que les vues globales ; l’étudiant voit *toutes* les vues. La perte n’est calculée que sur les paires de vues *différentes*, ce qui pousse l’étudiant à inférer le contexte global à partir d’un détail local (« local-to-global »).

Enseignant à momentum (EMA). L’enseignant n’est jamais entraîné par rétropropagation : ses poids suivent une moyenne mobile exponentielle de ceux de l’étudiant,

$$\theta_t \leftarrow \lambda \theta_t + (1 - \lambda) \theta_s, \quad (1)$$

avec λ suivant un planning cosinus de 0,996 vers 1. L’enseignant joue ainsi le rôle d’une cible stable et légèrement « en avance », analogue à un ensemble de modèles (Polyak averaging).

Perte et anti-effondrement. Soit P_t et P_s les distributions de l’enseignant et de l’étudiant. La perte est une entropie croisée

$$\mathcal{L} = \sum_{x \in \{x_1^g, x_2^g\}} \sum_{\substack{x' \in V \\ x' \neq x}} -P_t(x) \log P_s(x'), \quad (2)$$

où V est l’ensemble des vues. Deux mécanismes *complémentaires* évitent l’effondrement des représentations (tout mapper vers un même vecteur) :

- **centrage** : on soustrait à la sortie de l’enseignant une moyenne c mise à jour par EMA sur le batch ($c \leftarrow m c + (1 - m) \overline{g_{\theta_t}}$). Le centrage empêche une dimension de dominer ;
- **affûtage** (*sharpening*) : la température de l’enseignant τ_t est basse (0,04), ce qui produit des cibles piquées. L’affûtage empêche au contraire l’effondrement vers la distribution uniforme.

Centrage et affûtage agissent en sens opposés ; leur équilibre est crucial (objet de l’ablation A3).

2.2 Différences avec une ligne de base classique

Comparé à un entraînement supervisé standard, DINO se distingue par : (i) *absence d’étiquettes* — l’objectif est la cohérence inter-vues, pas la prédiction de classe ; (ii) *cible dynamique* — l’enseignant EMA remplace les étiquettes fixes ; (iii) *pas de paires négatives* ni de mémoire de contraste (contrairement à SimCLR/MoCo) et *pas de prédicteur* (contrairement à BYOL) ; (iv) *évaluation à features gelées* (k -NN), sans tête de classification entraînée. Ces choix rendent la méthode simple à implémenter tout en produisant des représentations transférables.

3 Cadre de reproduction

3.1 Ce qui est reproduit fidèlement

Le cœur de la méthode : architecture ViT + tête de projection, *multi-crop*, enseignant EMA, perte d'entropie croisée inter-vues, centrage + affûtage, planning cosinus du momentum et du taux d'apprentissage, règle de mise à l'échelle linéaire du LR ($\text{lr} = 0,0005 \times \text{bs}/256$), et l'évaluation k -NN à features gelées.

3.2 Jeu de données et prétraitements

STL-10 : split *unlabeled* (100 000 images 96×96) pour le pré-entraînement ; split *train* (5 000 images étiquetées) comme banque de référence k -NN et pour la ligne de base supervisée ; split *test* (8 000 images) pour l'évaluation. Augmentations : pour les vues globales, **RandomResizedCrop**(96, scale = [0,4,1]), flip horizontal, *color jitter*, niveaux de gris aléatoires, flou gaussien, puis normalisation par les moyennes/écarts-types de STL-10 ; pour les vues locales, recadrage 48×48 avec scale=[0,05,0,4]. L'évaluation utilise un simple **Resize/CenterCrop** à 96 sans augmentation.

3.3 Métriques et objets d'analyse

- **Précision k -NN top-1** ($k = 20$, similarité cosinus pondérée par température) sur les features gelées du backbone enseignant : mesure la qualité « brute » des représentations, sans entraînement supplémentaire.
- **Cartes d'auto-attention** du token [CLS] du dernier bloc ViT : preuve qualitative de l'émergence d'une attention sémantique.
- **Courbe de perte** de pré-entraînement (diagnostic de convergence / effondrement).

3.4 Ce qui est simplifié par rapport au papier

Le Tableau 1 résume les réductions. Elles sont *assumées* : l'objectif est de démontrer le mécanisme sous contrainte Colab, pas d'égaler les chiffres ImageNet. Le notebook expose un drapeau **FAST_MODE** ; les réglages fidèles au papier restent disponibles (**FAST_MODE=False**).

Table 1: Réglages du papier vs. notre reproduction réduite (mode **FAST_MODE**).

Élément	Papier (DINO)	Cette repro.
Jeu de données	ImageNet-1k (1,28 M)	STL-10 (sous-échant. 20 000)
Backbone	ViT-S/16, ViT-B/8	ViT-Tiny/8 ($\sim 5\text{--}6$ M)
Résolution	224	96 (global) / 48 (local)
Époques	300	40 (principal), 20 (ablations)
Taille de batch	1024	256
Dim. de sortie K	65 536	2 048
Vues (global+local)	2 + 8/10	2 + 4
Évaluation	lin. probing + k -NN	k -NN ($k=20$)

Justification des principaux choix. ViT-Tiny est la plus petite variante ViT standard et tient sur un GPU T4. Un patch de taille 8 sur des images 96 donne $12 \times 12 = 144$ tokens, suffisant pour une attention exploitable (un patch 16 n'en donnerait que 36). STL-10 est préféré à CIFAR-10/100 pour sa résolution *et* son split non étiqueté dédié au SSL. Le détail des arbitrages figure dans **decisions.md**.

4 Résultats

4.1 Reproduction principale et comparaison aux lignes de base

Le Tableau 2 compare la représentation DINO aux deux lignes de base de *même architecture*. La borne basse (initialisation aléatoire) situe le hasard ; la ligne de base supervisée fournit la comparaison « équitable » (même backbone, même protocole k -NN). On attend : aléatoire $\ll$ DINO, et DINO se rapprochant de — voire dépassant en k -NN — la version supervisée entraînée sur seulement 5 000 images étiquetées, illustrant l'intérêt d'exploiter 20 000 images *non* étiquetées.

Table 2: Précision k -NN top-1 (%) sur le test STL-10, features gelées, $k = 20$. Chiffres à compléter depuis `results/main_results.json`.

Méthode (backbone ViT-Tiny/8)	k -NN top-1 (%)
Initialisation aléatoire (borne basse)	[random_knn]
Supervisé (5 000 images étiquetées)	[supervised_knn]
DINO (auto-supervisé, 20 000 img.)	[dino_knn]
<i>Pour mémoire</i> : supervisé, précision de classification directe	[supervised_test_cls]

Figure 1: Courbe de perte du pré-entraînement DINO (`figures/loss_curve.png`). Une décroissance régulière sans plateau précoce à valeur dégénérée indique l'absence d'effondrement. *Insérer la figure après le run.*

4.2 Résultat qualitatif : attention émergente

La Figure 2 montre les cartes d'auto-attention du token [CLS] (dernier bloc). Conformément au papier (Figures 1 et 3), différentes têtes se spécialisent sur des régions sémantiques distinctes de l'objet, *sans aucune supervision*. C'est la propriété émergente phare de DINO ; sa présence à échelle réduite valide qualitativement notre reproduction.

Figure 2: Cartes d'attention par tête sur des images de test (`figures/attention_*.png`). *Insérer 1-2 exemples après le run.*

5 Ablation et extension

Nous reproduisons trois expériences inspirées de la Table 7 du papier, adaptées à notre cadre réduit (20 époques chacune). Chaque ablation ré-initialise un modèle et ne modifie *qu'un* composant. Le Tableau 3 regroupe les résultats.

A1 — Sans encodeur à momentum. *Changement* : l'enseignant devient une copie directe de l'étudiant à chaque pas (au lieu de l'EMA). *Hypothèse* : la cible n'est plus stable, le modèle *s'effondre* et la précision k -NN chute au niveau du hasard. C'est le composant le plus critique du papier (Table 7 : retrait du momentum $\rightarrow 0,1\%$). *Résultat* : [A1_no_momentum] % — *interpréter* : effondrement observé ? comparer à la borne aléatoire du Tableau 2.

A2 — Sans multi-crop. *Changement* : on retire les vues locales (2 vues globales seulement). *Hypothèse* : perte de l'objectif « local-to-global », baisse modérée de ~ 3 –5 points. *Résultat* : [A2_no_multicrop] % — *quantifier l'écart avec DINO complet*.

A3 — Balayage de la température de l’enseignant τ_t . *Changement* : $\tau_t \in \{0,04, 0,07, 0,10\}$. *Hypothèse* : une température trop haute sous-affûte les cibles et rapproche de l’effondrement (centrage non compensé), tandis qu’une température basse maintient des cibles piquées. C’est une mise en évidence directe de l’équilibre centrage/affûtage. *Résultats* : $\tau_t=0,04$: **[A3_tau_t=0.04]** % ; $\tau_t=0,07$: **[A3_tau_t=0.07]** % ; $\tau_t=0,10$: **[A3_tau_t=0.1]** %.

Table 3: Résumé des ablations (précision k -NN top-1 %, test STL-10). Source : `results/all_results.json`.

ID	Variante	k -NN top-1 (%)
—	DINO complet (référence)	[dino_knn]
A1	Sans momentum (copie directe)	[A1_no_momentum]
A2	Sans multi-crop (2 globales)	[A2_no_multicrop]
A3	$\tau_t = 0,04$	[A3_tau_t=0.04]
A3	$\tau_t = 0,07$	[A3_tau_t=0.07]
A3	$\tau_t = 0,10$	[A3_tau_t=0.1]

5.1 Extension personnelle : entraînement adaptatif piloté par la métrique aval

Plutôt que de fixer *a priori* la taille du jeu non étiqueté — un choix arbitraire qui influe fortement sur le résultat — nous proposons un protocole d’entraînement **adaptatif**. Le pool d’images non étiquetées croît par tranches de **CHUNK** (4000) ; après chaque tranche, on entraîne quelques époques puis on évalue un k -NN *sonde* rapide sur un petit échantillon tenu à l’écart (1000 réf./1000 requêtes). L’entraînement **s’arrête automatiquement** lorsque le gain de précision sonde passe sous un seuil (**min_delta**) pendant **patience** phases consécutives, ou atteint une cible. Le critère « combien de données suffisent ? » devient ainsi *empirique* : on lit directement sur la courbe (Figure 3) le point de saturation, et le meilleur modèle rencontré est conservé.

Motivation et hypothèse : le SSL devrait bénéficier de plus de données jusqu’à un plateau ; identifier ce plateau évite de gaspiller du calcul et justifie la taille retenue. *Limite* assumée : chaque phase ajoute simultanément des données *et* des pas d’optimisation, si bien que la courbe mêle effet-données et effet-durée ; nous l’interprétons donc comme un critère d’arrêt opérationnel, pas comme une loi d’échelle pure.

Figure 3: Entraînement adaptatif : précision k -NN sonde en fonction du nombre d’images non étiquetées utilisées (**figures/adaptive_curve.png**). Le plateau indique la taille de données suffisante ; *insérer après le run*. Arrêt à **[images]** images / **[epoch]** époques, meilleur k -NN sonde **[best_probe]** %.

6 Discussion critique

Ce qui fonctionne. *À compléter avec les chiffres.* Typiquement : DINO dépasse nettement la borne aléatoire, confirmant que le mécanisme apprend des représentations utiles à échelle réduite ; l’ablation A1 devrait montrer un effondrement franc, validant le rôle *load-bearing* de l’enseignant EMA ; les cartes d’attention sémantiques émergent même avec un ViT-Tiny peu entraîné.

Ce qui fonctionne mal ou reste incertain. *À compléter.* Pistes d’analyse honnête : l’écart DINO vs. supervisé peut être faible, voire défavorable, car (i) 40 époques et 20 000 images sont très en deçà du régime où le SSL brille, (ii) $K = 2048$ et un ViT-Tiny limitent la capacité, (iii) le k -NN à un seul k et une seule graine présente une variance non mesurée. Si une ablation ne

reproduit pas la tendance attendue (p.ex. A2 sans baisse nette), il faut le dire et l’expliquer (durée d’entraînement trop courte pour que le multi-crop paie, bruit d’estimation).

Différences avec le papier et limites. Nos chiffres absolus ne sont pas comparables à ceux du papier (dataset, résolution, durée, taille de K et de batch tous réduits). Les limites principales : (i) *budget de calcul* — une seule graine, pas d’intervalles de confiance ; (ii) *évaluation* — k -NN uniquement, pas de *linear probing* ; (iii) *échelle* — le régime de données est trop petit pour que l’avantage du SSL sur le supervisé se manifeste pleinement. Des extensions naturelles (hors budget ici) seraient : augmenter le sous-échantillon et les époques (**FAST_MODE=False**), ajouter le *linear probing*, et moyenner sur plusieurs graines.

Conclusion. Cette reproduction réduite isole et teste l’idée scientifique de DINO — la self-distillation sans étiquettes avec enseignant EMA, centrage et affûtage — montre comment elle se transpose à un cadre Colab/STL-10, et identifie par ablation quels composants modifient les résultats et pourquoi. Conformément à l’esprit du projet, nous privilégions une analyse honnête des résultats (y compris négatifs) à la course à la performance.

References

- [1] M. Caron, H. Touvron, I. Misra, H. Jégou, J. Mairal, P. Bojanowski, A. Joulin. *Emerging Properties in Self-Supervised Vision Transformers*. ICCV 2021. arXiv:2104.14294.
- [2] A. Dosovitskiy *et al.* *An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale*. ICLR 2021.
- [3] M. Oquab *et al.* *DINOv2: Learning Robust Visual Features without Supervision*. arXiv:2304.07193, 2023.