

Reproduction réduite de DINO

Emerging Properties in Self-Supervised Vision Transformers

sur STL-10 avec un ViT-Tiny

Namie Pajot Alexandra Arucan Mael Zapata Philipp Widenfels

Albert School — Bachelor Business & Data (3^e année)

Cours : Introduction to Deep Learning — Encadrant : A. Bouru-Gazeau

Résumé

Dans ce projet, on cherche à reproduire l'idée centrale de **DINO** [1] : apprendre des représentations visuelles sans aucune étiquette, en faisant correspondre les sorties d'un réseau étudiant à celles d'un réseau enseignant construit comme moyenne mobile exponentielle (EMA) de l'étudiant. On entraîne un *ViT-Tiny* (patch 8, environ 5,5 M paramètres pour le backbone, 11 M avec la tête de projection) sur STL-10, et on évalue la qualité des représentations obtenues avec un classifieur k -NN, qu'on compare à deux références de même architecture : une initialisation aléatoire et un entraînement supervisé classique. On retrouve en partie la propriété émergente mise en avant dans le papier, à savoir des cartes d'auto-attention qui se structurent autour des objets sans aucune supervision, même si elles restent bruitées à notre échelle. On mène aussi trois ablations tirées de la Table 7 du papier, sur l'encodeur à momentum, le multi-crop et la température de l'enseignant. En comparant à durée égale avec les résultats du papier, l'effondrement provoqué par le retrait du momentum se reproduit clairement, tandis que les effets du multi-crop et de la température, présents et dans le bon sens, restent atténués par notre budget réduit. L'objectif n'est pas d'égaler les performances sur ImageNet mais de vérifier que le mécanisme fonctionne à petite échelle et que nos ablations retrouvent qualitativement les mêmes conclusions.

Code, notebook et figures : <https://github.com/Beginner4ever/DINO-Saure>

Table des matières

1	Introduction	1
2	Méthode	1
2.1	Vue d'ensemble de DINO	1
2.2	Différences avec une ligne de base classique	3
3	Cadre de reproduction	3
3.1	Ce qui est reproduit fidèlement	3
3.2	Jeu de données et prétraitements	3
3.3	Métriques et objets d'analyse	3
3.4	Ce qui est simplifié par rapport au papier	3
3.5	Contraintes d'exécution : Colab T4 vs. Apple MPS	4
4	Résultats	4
4.1	Reproduction principale et comparaison aux lignes de base	4
4.2	Résultat qualitatif : attention émergente	5
5	Ablation et extension	6
5.1	Extension personnelle : entraînement adaptatif piloté par la métrique aval	7
6	Discussion critique	8

Table des figures

1	Architecture de DINO	2
---	--------------------------------	---

2	Comparaison aux lignes de base	5
3	Cartes d'auto-attention	6
4	Ablations appariées et balayage de température	7
5	Boucle d'entraînement adaptatif	8
6	Saturation des représentations	8

Liste des tableaux

1	Réglages : papier vs. reproduction	4
2	Résultats k -NN principaux	5
3	Résumé des ablations	7

1 Introduction

Papier choisi. DINO — *Emerging Properties in Self-Supervised Vision Transformers*, Caron *et al.*, ICCV 2021 (arXiv :2104.14294) [1]. DINO (*self-distillation with **no** labels*) est une méthode d'apprentissage auto-supervisé (SSL) qui apprend des représentations visuelles sans étiquettes en faisant correspondre les sorties d'un réseau *étudiant* à celles d'un réseau *enseignant* construit à partir de l'étudiant lui-même.

Pourquoi ce papier. On a choisi ce papier pour trois raisons. D'abord la pertinence : le pré-entraînement auto-supervisé répond directement au problème du coût d'annotation, qui est un vrai goulot d'étranglement dans les pipelines réels, et DINOv2 (Meta, 2023) en est le descendant direct, largement utilisé en production aujourd'hui. Ensuite l'évaluabilité : la contribution est à la fois quantitative, avec la précision k -NN sur des représentations gelées, et qualitative, avec des cartes d'attention qui segmentent les objets, ce qui permet un rapport plus riche qu'une simple courbe de loss. Enfin la faisabilité : l'algorithme tient en une quinzaine de lignes de pseudo-code (Algorithme 1 du papier), ce qui rend une reproduction réduite réaliste sur Colab. On avait aussi envisagé MAE [7], Barlow Twins [8] et DDPM [9], mais on les a écartés : MAE donne des résultats visuels moins frappants à petite échelle, Barlow Twins offre un espace d'ablation plus pauvre, et DDPM demande un budget de calcul incompatible avec Colab.

Données et angle d'analyse. Nous travaillons sur **STL-10**, choisi pour sa résolution 96×96 (adaptée à la tokenisation en patches d'un ViT) et son *split non étiqueté* de 100 000 images, conçu pour le SSL. Notre angle est double :

1. **quantitatif** : la représentation auto-supervisée est-elle utile sans fine-tuning ? On mesure ça avec un k -NN sur les features gelées, qu'on compare à une baseline supervisée de même architecture et à une borne basse par initialisation aléatoire.
2. **qualitatif et mécaniste** : la propriété émergente (attention sémantique) se manifeste-t-elle à échelle réduite, et quels composants sont *indispensables* pour éviter l'effondrement (*collapse*) des représentations ? C'est l'objet de nos ablations.


2 Méthode

2.1 Vue d'ensemble de DINO

DINO entraîne deux réseaux de même architecture, un étudiant g_{θ_s} et un enseignant g_{θ_t} . Chacun est composé d'un *backbone* (ici un ViT) suivi d'une tête de projection produisant un vecteur de dimension K , transformé en distribution de probabilité par un softmax avec température. L'objectif est de rendre la distribution de l'étudiant cohérente avec celle de l'enseignant sur *des vues différentes de la même image*. La Figure 1 en résume l'architecture.

Multi-crop. À partir d'une image, on génère un ensemble de vues : 2 vues *globales* (grandes) et plusieurs vues *locales* (petites). L'enseignant ne voit que les vues globales ; l'étudiant voit *toutes* les vues. La perte n'est calculée que sur les paires de vues *différentes*, ce qui pousse l'étudiant à inférer le contexte global à partir d'un détail local (« local-to-global »).

DINO : self-distillation sans étiquettes



L'enseignant ne voit que les vues globales ; l'étudiant voit toutes les vues.

FIGURE 1 – Architecture de DINO. Une image produit 2 vues globales (96×96) et 4 vues locales (48×48). L'enseignant, moyenne mobile (EMA) de l'étudiant, non entraîné par rétropropagation, ne traite que les vues globales. L'étudiant traite toutes les vues. Chaque branche enchaîne un ViT-Tiny puis une tête de projection ($K = 2048$). La perte est l'entropie croisée entre la distribution *enseignant* (centrée puis affûtée) et la distribution *étudiant*, sur les paires de vues différentes.

Enseignant à momentum (EMA). L'enseignant n'est jamais entraîné par rétropropagation : ses poids suivent une moyenne mobile exponentielle de ceux de l'étudiant,

$$\theta_t \leftarrow \lambda \theta_t + (1 - \lambda) \theta_s, \quad (1)$$

où λ augmente progressivement de 0,996 vers 1 au cours de l'entraînement. L'enseignant fournit ainsi une cible plus stable, qui évolue lentement et guide l'apprentissage de l'étudiant.

Perte et anti-effondrement. Soit P_t et P_s les distributions de l'enseignant et de l'étudiant. La perte est une entropie croisée

$$\mathcal{L} = \sum_{x \in \{x_1^g, x_2^g\}} \sum_{\substack{x' \in V \\ x' \neq x}} -P_t(x) \log P_s(x'), \quad (2)$$

où V est l'ensemble des vues. Deux mécanismes *complémentaires* évitent l'effondrement des représentations (tout mapper vers un même vecteur) :

- **centrage** : on soustrait à la sortie de l'enseignant une moyenne c mise à jour par EMA sur le batch ($c \leftarrow m c + (1 - m) \overline{g_{\theta_t}}$). Le centrage empêche une dimension de dominer ;
- **affûtage** (*sharpening*) : la température de l'enseignant τ_t est basse (0,04), ce qui produit des cibles piquées. L'affûtage empêche au contraire l'effondrement vers la distribution uniforme.

Centrage et affûtage agissent en sens opposés ; leur équilibre est crucial (objet de l'ablation A3).

2.2 Différences avec une ligne de base classique

Comparé à un entraînement supervisé standard, DINO se distingue par : (i) *absence d'étiquettes* : l'objectif est la cohérence inter-vues, pas la prédiction de classe ; (ii) *cible dynamique* : l'enseignant EMA remplace les étiquettes fixes ; (iii) *pas de paires négatives* ni de mémoire de contraste (contrairement à SimCLR [4] / MoCo [5]) et *pas de prédicteur* (contrairement à BYOL [6]) ; (iv) *évaluation à features gelées* (k -NN), sans tête de classification entraînée. Ces choix rendent la méthode simple à implémenter tout en produisant des représentations transférables.

3 Cadre de reproduction

3.1 Ce qui est reproduit fidèlement

Le cœur de la méthode : architecture ViT + tête de projection, *multi-crop*, enseignant EMA, perte d'entropie croisée inter-vues, centrage + affûtage, augmentation progressive du momentum et du taux d'apprentissage au cours de l'entraînement, et l'évaluation k -NN sur représentations gelées.

3.2 Jeu de données et prétraitements

STL-10 : split *unlabeled* (100 000 images 96×96) pour le pré-entraînement ; split *train* (5 000 images étiquetées) comme banque de référence k -NN et pour la ligne de base supervisée ; split *test* (8 000 images) pour l'évaluation. Augmentations : pour les vues globales, **RandomResizedCrop**(96, scale = [0,4, 1]), flip horizontal, *color jitter*, niveaux de gris aléatoires, flou gaussien, puis normalisation par les moyennes/écarts-types de STL-10 ; pour les vues locales, recadrage 48×48 avec **scale**=[0,05, 0,4]. L'évaluation utilise un simple **Resize/CenterCrop** à 96 sans augmentation.

3.3 Métriques et objets d'analyse

- **Précision k -NN top-1** ($k = 20$, similarité cosinus) sur les représentations gelées du backbone enseignant. Nous évaluons par k -NN plutôt que par un classifieur entraîné car cette méthode *n'apprend rien* : chaque image de test est classée par vote de ses plus proches voisins dans l'espace des représentations. Le score reflète donc directement la qualité des représentations apprises sans supervision. Un classifieur entraîné, lui, pourrait masquer des représentations médiocres en s'y ajustant. C'est aussi le protocole d'évaluation du papier.
- **Cartes d'auto-attention** du token [CLS] du dernier bloc ViT : preuve qualitative de l'émergence d'une attention sémantique.
- **Courbe k -NN sonde** de l'entraînement adaptatif (diagnostic de convergence et de saturation, Figure 6).

3.4 Ce qui est simplifié par rapport au papier

Le Tableau 1 résume les réductions. Elles sont *assumées* : l'objectif est de démontrer le mécanisme sous contrainte Colab, pas d'égaliser les chiffres ImageNet. Le notebook expose un drapeau **FAST_MODE** ; les réglages fidèles au papier restent disponibles (**FAST_MODE=False**).

Justification des principaux choix. ViT-Tiny est la plus petite variante ViT standard et tient sur un GPU T4. Un patch de taille 8 sur des images 96 donne $12 \times 12 = 144$ tokens, suffisant pour une

TABLE 1 – Réglages du papier vs. notre reproduction réduite (mode `FAST_MODE`).

Élément	Papier (DINO)	Cette repro.
Jeu de données	ImageNet-1k (1,28 M)	STL-10 (adaptatif, $\leq 24\,000$)
Backbone	ViT-S/16, ViT-B/8	ViT-Tiny/8 (<i>backbone</i> $\sim 5,5$ M)
Résolution	224	96 (global) / 48 (local)
Époques	300	~ 60 (adaptatif), 20 (ablations)
Taille de batch	1024	256
Dim. de sortie K	65 536	2 048
Vues (global+local)	2 + 8/10	2 + 4
Évaluation	classif. linéaire + k -NN	k -NN ($k=20$)

attention exploitable (un patch 16 n’en donnerait que 36). STL-10 est préféré à CIFAR-10/100 pour sa résolution *et* son split non étiqueté dédié au SSL. Le détail des arbitrages figure dans `decisions.md`.

3.5 Contraintes d’exécution : Colab T4 vs. Apple MPS

Le notebook visait initialement le GPU **T4** de Google Colab (`FAST_MODE` y est calibré pour $\sim 2\text{--}3$ h). Deux obstacles concrets nous ont fait migrer l’exécution :

- **Mémoire GPU.** Aux réglages par défaut (batch 256), la passe *multi-crop*, six vues par image (2 globales 96^2 + 4 locales 48^2) traversant l’étudiant *et* l’enseignant, tête de dimension $K = 2048$, déclenche une *OutOfMemoryError* sur le T4 (16 Go). On la contourne en divisant le batch par deux ($256 \rightarrow 128$) et en réduisant le taux d’apprentissage en proportion, au prix d’un réglage dégradé.
- **Coupures de session.** Le *runtime* gratuit se déconnecte sur inactivité ; combiné à un entraînement de plusieurs heures, cela rend peu fiable l’achèvement du pipeline avant l’échéance.

Nous avons donc basculé sur une machine locale **Apple Silicon (M3)** via le *backend* **MPS** de PyTorch, échangeant du débit brut contre une exécution *ininterrompue* (pas de coupure de session ; 36 Go de mémoire unifiée). Cela a exigé quelques adaptations propres à MPS :

- `dynamic_img_size=True` sur le ViT (timm), pour accepter les vues locales 48×48 : sans cela le *patch embed* (strict) rejette toute entrée $\neq 96$ et le multi-crop ne tourne pas ; les plongements de position sont alors ré-interpolés par taille de vue.
- L’opérateur `_upsample_bicubic2d_aa_backward` (rétropropagation de cette interpolation) n’est pas implémenté sur MPS et bascule sur CPU (léger surcoût) ; certaines optimisations mémoire ne sont pas disponibles non plus, et l’entraînement se fait en simple précision (`float32`).

Au final, le *pipeline* complet (pré-entraînement adaptatif + baseline supervisée + ablations A1/A2) a tourné sans interruption en ~ 6 h sur le GPU intégré, là où l’environnement T4 — même après réduction du batch — restait sujet aux déconnexions et ne garantissait pas l’achèvement avant l’échéance. Cette dualité résume un arbitrage fréquent en pratique : *débit* (CUDA/T4) contre *disponibilité et continuité* (MPS local).

4 Résultats

4.1 Reproduction principale et comparaison aux lignes de base

Le Tableau 2 (illustré par la Figure 2) compare la représentation DINO aux deux lignes de base de *même architecture*. La borne basse (initialisation aléatoire) situe le hasard ; la ligne de base su-

pervisée fournit la comparaison « équitable » (même backbone, même protocole k -NN). On s’attend à ce que l’aléatoire soit largement en dessous de DINO, et que DINO se rapproche voire dépasse en k -NN la version supervisée entraînée sur seulement 5 000 images étiquetées, ce qui illustrerait l’intérêt d’exploiter 20 000 images *non* étiquetées.

TABLE 2 – Précision k -NN top-1 (%) sur le test STL-10, features gelées, $k = 20$. Source : `results/main_results.json`.

Méthode (backbone ViT-Tiny/8)	k -NN top-1 (%)
Initialisation aléatoire (borne basse)	27,4
Supervisé (5 000 images étiquetées)	52,6
DINO (auto-supervisé, $\leq 24\,000$ img.)	37,2
<i>Pour mémoire</i> : supervisé, précision de classification directe	49,8




FIGURE 2 – Représentations gelées : précision k -NN sur STL-10 (mêmes chiffres que le Tableau 2). DINO (37,2 %) dépasse largement la borne aléatoire (27,4 %) mais reste sous la baseline supervisée de même architecture (52,6 %).

Remarque. Nous avons retenu le protocole **adaptatif** (§5b du notebook) plutôt que le pré-entraînement à durée fixe (§5); `figures/loss_curve.png` n’est donc pas produit. Le diagnostic de convergence (absence d’effondrement) est fourni par la courbe d’entraînement adaptatif (Figure 6), dont la précision k -NN sonde croît de façon monotone.

4.2 Résultat qualitatif : attention émergente

La Figure 3 montre les cartes d’auto-attention du token [CLS] (dernier bloc). On voit une attention spatialement structurée où certaines têtes se concentrent plutôt sur l’objet que sur le fond, même si c’est nettement plus bruité qu’avec les grands modèles du papier (Figures 1 et 3). Cette structuration reste imparfaite avec un ViT-Tiny peu entraîné, mais elle va quand même dans le sens de la propriété émergente de DINO. On l’interprète comme un signal qualitatif encourageant, pas comme une segmentation propre.



FIGURE 3 – Cartes d’auto-attention par tête (token [CLS], dernier bloc) sur deux images de test STL-10 (`figures/attention_dog.png`, `attention_horse.png`). Différentes têtes tendent à se concentrer sur l’objet plutôt que sur le fond (attention bruitée à cette échelle réduite), *sans aucune supervision*.

5 Ablation et extension

Nous menons trois ablations inspirées de la Table 7 du papier, adaptées à notre cadre réduit (20 époques chacune, à *configuration appariée*). Chaque ablation ré-initialise un modèle et ne modifie qu’un composant. Le Tableau 3 et la Figure 4 regroupent les résultats.

A1 — Sans encodeur à momentum. *Changement* : l’enseignant devient une copie directe de l’étudiant à chaque pas (au lieu de l’EMA). *Hypothèse* : la cible n’est plus stable, le modèle *s’effondre* et la précision k -NN chute au niveau du hasard. C’est le composant le plus critique du papier (Table 7 : retrait du momentum $\rightarrow$ 0,1 %). *Résultat* : **19,6 %**, effondrement confirmé. La précision tombe *sous* la borne aléatoire (27,4 %, Tab. 2) et la perte de pré-entraînement *diverge* (5,5 $\rightarrow$ 8,4), double signature de l’effondrement. Le papier rapporte 0,1 % (le hasard sur 1000 classes) ; à 10 classes, où l’initialisation aléatoire atteint déjà 27,4 %, l’effondrement se lit comme un modèle *pire* que l’aléatoire. L’entraînement dégénéré a détruit la structure pourtant présente à l’initialisation.

A2 — Sans multi-crop. *Changement* : on retire les vues locales (2 vues globales seulement). *Hypothèse* : perte de l’objectif « local-to-global », baisse modérée de ~ 3 –5 points. *Résultat* : **31,6 %**. *Précaution sur la comparaison* : opposer naïvement A2 à DINO complet (37,2 %) donne $-5,6$ points, mais ce DINO complet est entraîné plus longtemps (60 époques adaptatives). L’écart mêle alors l’effet du multi-crop *et* celui de la durée. La comparaison à *durée égale* oppose A2 à la configuration complète de A3 ($\tau_t=0,04$: 32,4 %, mêmes 20 époques ; seule la présence du multi-crop change) : le multi-crop ne vaut alors que $\sim 0,8$ point, bien en deçà des $-4,9$ points du papier (300 époques). Le $-5,6$ se décompose ainsi en $\sim 4,8$ pt de durée (20 $\rightarrow$ 60 époques) et $\sim 0,8$ pt de multi-crop. *Interprétation honnête* : à 20 époques, l’objectif local-to-global du multi-crop n’a pas le temps de payer. Son bénéfice croît avec la durée, d’où une *divergence* assumée avec le papier. La variante reste stable (enseignant EMA conservé), sans effondrement contrairement à A1.

A3 — Balayage de la température de l’enseignant τ_t . *Changement* : $\tau_t \in \{0,04, 0,07, 0,10\}$. *Hypothèse* : une température trop haute sous-affûte les cibles et rapproche de l’effondrement (centrage

non compensé), tandis qu’une température basse maintient des cibles piquées. C’est une mise en évidence directe de l’équilibre centrage/affûtage. *Résultats* (Figure 4, droite) : $\tau_t=0,04$: **32,4 %** ; $\tau_t=0,07$: 31,5 % ; $\tau_t=0,10$: 30,9 %. La précision décroît de façon *monotone* quand τ_t augmente, exactement la direction attendue : une température basse *affûte* les cibles de l’enseignant et aide, une température haute les adoucit et dégrade. L’effet reste modeste à notre échelle ($\sim 1,4$ pt sur tout le balayage), mais sa monotonie et le fait que la valeur par défaut du papier ($\tau_t=0,04$) ressorte en tête confirment qualitativement le rôle de l’affûtage. Aucune valeur de la plage testée ne provoque d’effondrement : le centrage, toujours actif, suffit ici à l’éviter.

TABLE 3 – Résumé des ablations (précision k -NN top-1 %, test STL-10). Source : `results/all_results.json`.

ID	Variante	k -NN top-1 (%)
—	Config. complète, 20 ép. ($\tau_t=0,04$, réf.)	32,4
A1	sans momentum	19,6
A2	sans multi-crop	31,6
A3	température $\tau_t = 0,07$	31,5
A3	température $\tau_t = 0,10$	30,9
<i>Pour mémoire</i> : DINO complet, 60 ép. adaptatif (Tab. 2)		37,2




FIGURE 4 – **Gauche** : ablations à *durée égale* (20 époques). Retirer le momentum (A1) effondre la représentation *sous* la borne aléatoire ; retirer le multi-crop (A2) ne coûte que $-0,8$ pt face à la configuration complète (32,4 %), bien moins que les $-4,9$ pt du papier, l’objectif local-to-global n’ayant pas le temps de payer en 20 époques. **Droite** : balayage de la température enseignante (A3) ; la précision décroît de façon monotone quand τ_t augmente, $\tau_t=0,04$ (défaut du papier) en tête.

5.1 Extension personnelle : entraînement adaptatif piloté par la métrique aval

Plutôt que de fixer *a priori* la taille du jeu non étiqueté (un choix arbitraire qui influe fortement sur le résultat), nous proposons un protocole d’entraînement **adaptatif**. Le pool d’images non étiquetées croît par tranches de `CHUNK` (4000) ; après chaque tranche, on entraîne quelques époques puis on évalue un k -NN sonde rapide sur un petit échantillon tenu à l’écart (1000 réf./1000 requêtes). L’entraînement **s’arrête automatiquement** lorsque le gain de précision sonde passe sous un seuil (`min_delta`) pendant `patience` phases consécutives, ou atteint une cible. Le critère « combien de

données suffisent ? » devient ainsi *empirique* : on lit directement sur la courbe (Figure 6) le point de saturation, et le meilleur modèle rencontré est conservé. La Figure 5 schématise cette boucle.

Extension : entraînement adaptatif piloté par la métrique aval




FIGURE 5 – Boucle d’entraînement adaptatif : le pool non étiqueté croît par tranches ; on entraîne, puis on sonde un k -NN sur une validation tenue à l’écart ; l’arrêt se déclenche dès que le gain passe sous un seuil. La quantité de données « suffisante » devient ainsi empirique plutôt qu’arbitraire.

Motivation et hypothèse : le SSL devrait bénéficier de plus de données jusqu’à un plateau ; identifier ce plateau évite de gaspiller du calcul et justifie la taille retenue. *Limite* assumée : chaque phase ajoute simultanément des données *et* des pas d’optimisation, si bien que la courbe mêle effet-données et effet-durée ; nous l’interprétons donc comme un critère d’arrêt opérationnel, pas comme une loi d’échelle pure.




FIGURE 6 – Entraînement adaptatif : précision k -NN sonde en fonction du nombre d’images non étiquetées utilisées ; la bande grisée indique l’incertitude de la sonde, calculée sur seulement 1000 images de validation ($\sim \pm 1,5$ pt). La précision croît de 23,7 % (4000 img.) à 31,6 % (24000 img.), avec un gain marginal décroissant sur la dernière tranche (31,0 $\rightarrow$ 31,6 %, soit +0,6 pt). Ce dernier gain étant plus petit que l’incertitude de mesure sur 1000 images, on ne peut pas le considérer comme fiable : la courbe a donc saturé. Arrêt à 24 000 images / 60 époques, meilleur k -NN sonde 31,6 %.

6 Discussion critique

Ce qui fonctionne. DINO (37,2 %) dépasse nettement la borne aléatoire (27,4 %, soit +9,8 points), confirmant que la self-distillation apprend des représentations utiles *sans aucune étiquette* à échelle

réduite. L’ablation A1 produit un effondrement franc (19,6 %, sous l’aléatoire, perte divergente), validant le rôle *essentiel* de l’enseignant EMA, exactement la conclusion de la Table 7 du papier (retrait du momentum $\rightarrow 0,1\%$). L’effet du *multi-crop*, en revanche, ne se reproduit pas : mesuré à *durée égale* (A2 contre la configuration complète de A3, mêmes 20 époques), il ne vaut que $\sim 0,8$ pt, loin des $-4,9$ pt du papier, vraisemblablement parce qu’à 20 époques son objectif local-to-global n’a pas le temps de payer. Comparer naïvement A2 à DINO complet (60 époques) gonflait cet écart à $-5,6$ pt en y mêlant la durée d’entraînement. Le balayage de température (A3) confirme, lui, la direction du papier (plus τ_t est bas, meilleure est la sonde). Enfin, on observe une attention spatialement structurée (concentrée sur l’objet) même avec un ViT-Tiny peu entraîné, indice qualitatif (quoique bruité) de la propriété émergente (Figure 3).

Ce qui fonctionne mal ou reste incertain. Contrairement au papier, où le k -NN DINO rivalise avec les features supervisées, notre DINO (37,2 %) reste *en deçà* du supervisé (52,6 %). C’est attendu et instructif : (i) 24 000 images et ~ 60 époques sont très en deçà du régime où le SSL brille (le papier utilise 1,28 M d’images, 300 époques) ; (ii) $K = 2048$ et un ViT-Tiny limitent la capacité ; (iii) le k -NN, mesuré avec un seul k et une seule graine aléatoire, peut varier d’une exécution à l’autre. La courbe adaptative (Figure 6) étaye cette lecture : la précision sonde *croît encore* à 24 000 images ($23,7 \rightarrow 31,6\%$) sans saturer pleinement. L’écart au supervisé est donc une limite de *données/calcul*, non un défaut de la méthode, et se réduirait à plus grande échelle, en cohérence avec le papier.

Différences avec le papier et limites. Nos chiffres absolus ne sont pas comparables à ceux du papier (dataset, résolution, durée, taille de K et de batch tous réduits). Les limites principales : (i) *budget de calcul* : une seule exécution, sans moyenne sur plusieurs essais ; (ii) *évaluation* : k -NN uniquement, sans entraîner de classifieur linéaire sur les représentations gelées ; (iii) *échelle* : le régime de données est trop petit pour que l’avantage du SSL sur le supervisé se manifeste pleinement. Des extensions naturelles (hors budget ici) seraient : augmenter le sous-échantillon et les époques (FAST_MODE=False), et répéter l’entraînement avec plusieurs graines aléatoires pour vérifier la stabilité des résultats.

Conclusion. Cette reproduction réduite isole et teste l’idée scientifique de DINO, la self-distillation sans étiquettes avec enseignant EMA, centrage et affûtage, montre comment elle se transpose à un cadre Colab/STL-10, et identifie par ablation quels composants modifient les résultats et pourquoi. Conformément à l’esprit du projet, nous privilégions une analyse honnête des résultats (y compris négatifs) à la course à la performance.

Références

- [1] M. Caron, H. Touvron, I. Misra, H. Jégou, J. Mairal, P. Bojanowski, A. Joulin. *Emerging Properties in Self-Supervised Vision Transformers*. ICCV 2021. arXiv :2104.14294.
- [2] A. Dosovitskiy *et al.* *An Image is Worth 16x16 Words : Transformers for Image Recognition at Scale*. ICLR 2021.
- [3] M. Oquab *et al.* *DINOv2 : Learning Robust Visual Features without Supervision*. arXiv :2304.07193, 2023.

- [4] T. Chen, S. Kornblith, M. Norouzi, G. Hinton. *A Simple Framework for Contrastive Learning of Visual Representations*. ICML 2020.
- [5] K. He, H. Fan, Y. Wu, S. Xie, R. Girshick. *Momentum Contrast for Unsupervised Visual Representation Learning*. CVPR 2020.
- [6] J.-B. Grill *et al.* *Bootstrap Your Own Latent : A New Approach to Self-Supervised Learning*. NeurIPS 2020.
- [7] K. He, X. Chen, S. Xie, Y. Li, P. Dollár, R. Girshick. *Masked Autoencoders Are Scalable Vision Learners*. CVPR 2022.
- [8] J. Zbontar, L. Jing, I. Misra, Y. LeCun, S. Deny. *Barlow Twins : Self-Supervised Learning via Redundancy Reduction*. ICML 2021.
- [9] J. Ho, A. Jain, P. Abbeel. *Denoising Diffusion Probabilistic Models*. NeurIPS 2020.